- 1. The number of word tokens in the database (before): 240535
- 2. The number of unique words in the database: 7377 The number of word tokens in the database (after): 114826
- 3. The number of words that occur only once in the database: 2850
- 4. The average number of word tokens per document: 317.06188118811883
- 4. For 30 most frequent words in the database, provide: TF, scaled TF (1+log(tf), IDF, TF*IDF and probabilities

```
For 30 most frequent words in the database, provide:
                 N : Tf(weight): df : IDF
Term :
          Tf:
                                             : TF.IdF
                                                            : probabilities
          3119 : 404 : 9.0453
                                : 363 : 0.1070 : 333.7706
                                                            : 0.0272
          2418 : 404 : 8.7907
                               : 404 : 0.0000 : 0.0000
                                                            : 0.0211
          2377 : 404 : 8.7736
                               : 338 : 0.1784 : 423.9831
                                                           : 0.0207
um
                               : 358 : 0.1209 : 270.7754
                                                            : 0.0195
know:
          2240 :
                 404 : 8.7142
qo
          1689 : 404 : 8.4319
                                : 392 : 0.0302 : 50.9285
                                                              0.0147
                               : 308 : 0.2713 : 386.8953
                                                            : 0.0124
          1426 : 404 : 8.2626
realli:
          1153 : 404 : 8.0501
                               : 332 : 0.1963 : 226.3107
one :
                                                            : 0.0100
get
          1049 : 404 : 7.9556
                              : 304 : 0.2844 : 298.3221
                                                           : 0.0091
                               : 278 : 0.3738 : 379.0269
                                                            : 0.0088
video :
          1014 : 404 : 7.9217
                               : 400 : 0.0100 : 9.7414
           979 :
                 404 : 7.8865
re
                                                               0.0085
           962 : 404 : 7.8690
                                : 233 : 0.5504 : 529.4621
uh
                                                              0.0084
                                : 255 : 0.4602 : 407.6941
yeah :
           886 : 404 : 7.7867
                                                            : 0.0077
           834 : 404 : 7.7262
                              : 264 : 0.4255 : 354.8385
 think :
                                                            : 0.0073
           827 : 404 : 7.7178
want :
                              : 270 : 0.4030 : 333.2751
                                                           : 0.0072
                               : 236 : 0.5376 : 427.9161
                                                           : 0.0069
peopl :
           796 : 404 : 7.6796
                                : 270 : 0.4030 : 310.3045
 thing:
           770 :
                 404 : 7.6464
                                                               0.0067
                                                            :
           742 : 404 : 7.6093
                                : 394 : 0.0251 : 18.5975
ve
                                                              0.0065
                                                            : 0.0062
make :
           712 : 404 : 7.5681
                                : 279 : 0.3702 : 263.5846
           671 : 404 : 7.5088
                                : 267 : 0.4142 : 277.9055
                                                            : 0.0058
say
     :
ll
           662 : 404 : 7.4953
                              : 396 : 0.0200 : 13.2404
                                                            : 0.0058
                               : 286 : 0.3454 : 226.2521
                                                            : 0.0057
           655 : 404 : 7.4846
see
     :
                                : 215 : 0.6308 : 384.1431
           609 :
                 404 : 7.4118
guy
      :
                                                               0.0053
           603 : 404 : 7.4019
                                : 252 : 0.4720 : 284.6074
                                                            : 0.0053
time
           603 : 404 : 7.4019
                                : 258 : 0.4485 : 270.4185
                                                            : 0.0053
aot
           558 : 404 : 7.3244
                               : 242 : 0.5125 : 285.9623
right :
                                                            : 0.0049
                                                           : 0.0048
xxxx :
           548 : 404 : 7.3063
                              : 175 : 0.8366 : 458.4726
                               : 237 : 0.5334 : 289.0783
                                                          : 0.0047
           542 : 404 : 7.2953
good :
                               : 215 : 0.6308 : 322.9577
                                                          : 0.0045
: 0.0044
would :
           512 :
                 404 : 7.2383
           509 : 404 : 7.2324
                                : 221 : 0.6033 : 307.0554
well :
                                                          : 0.0044
           507 : 404 : 7.2285 : 228 : 0.5721 : 290.0391
lot
Done
```